

datathon_jour1_analyse

June 24, 2026

1 Datathon — Jour 1 : Comprendre le corpus (affaire Ultia × CNC)

Objectif du jour : lire, comprendre et analyser le corpus. Remplir la grille à 5 axes (Acteurs / Narratifs / Propagation / Coordination / Sémantique), produire une timeline et 2-3 chiffres clés.

Règle d'or (slide 'le piège à éviter') : ce n'est PAS un cas de fausse information, c'est un déferlement viral. On décrit la dynamique avant de juger. Ton neutre.

On ne touche pas encore aux agents. Aujourd'hui = analyse pure.

1.0.1 Convention d'équipe (à respecter par les 9 pour que les chiffres soient comparables)

- Colonne temps de référence : **Date** (datetime).
- Fenêtre de crise principale : **26-30 mars 2026**.
- Un *message original* = ligne où **Engagement Type** est vide.
- Toujours travailler sur `message_normalize` pour le texte (déjà nettoyé).

1.1 0. Setup & chargement

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from collections import Counter

# --- Sur Colab : décommenter pour uploader data.xlsx ---
from google.colab import files
files.upload()

df = pd.read_excel('data.xlsx')
df['Date'] = pd.to_datetime(df['Date'])
print('Lignes:', len(df), '| Colonnes:', df.shape[1])
print('Période:', df['Date'].min(), '->', df['Date'].max())
df.head(3)
```

<IPython.core.display.HTML object>

Saving data.xlsx to data.xlsx
 Lignes: 35396 | Colonnes: 30
 Période: 2026-03-19 23:13:01 -> 2026-05-01 21:43:00

```
[1]:
```

	Date	Url	\
0	2026-05-01 21:43:00	http://twitter.com/Chaumont_Loire/statuses/205...	
1	2026-05-01 21:38:40	http://twitter.com/GuzmanStephane/statuses/205...	
2	2026-05-01 21:37:39	http://twitter.com/Lancelo34643571/statuses/20...	

	Domain	Sentiment	Language	Country	City	Code	Author	City	\
0	twitter.com	neutral	fr	France		NaN	Chaumont_Loire	NaN	
1	twitter.com	neutral	fr	France		NaN	GuzmanStephane	NaN	
2	twitter.com	neutral	fr	France		NaN	Lancelo34643571	NaN	

	Expanded URLs	...	X Reply to	\
0	https://www.cnc.fr/cinema/actualites/le-jardin...	...	NaN	
1	https://x.com/FrDesouche/status/20501420077717...	...	NaN	
2	https://x.com/JPatrierLeitus/status/2049899199...	...	NaN	

	X Repost of	X Posts	X Verified	\
0	NaN	9211	False	
1	http://twitter.com/destinationcine/statuses/20...	348374	False	
2	http://twitter.com/FrDesouche/statuses/2050109...	126326	False	

	Reach	Engagement	Type	Hashtags	postID	postDate	\
0	3434		NaN	#googlealerts	1	2026-05-01	
1	851		RETWEET	NaN	2	2026-05-01	
2	2039		RETWEET	NaN	3	2026-05-01	


```
message_normalizer
```

0	« le jardin fait son cinema » au festival int...
1	rt @ destinationcine le clip " storm " de roma...
2	rt @ frdesouche la choregraphie est formidable...

[3 rows x 30 columns]

1.2 1. Vue d'ensemble — les 4 chiffres qui cadrent tout

Avant les 5 axes, on pose le décor. Ces chiffres sont le socle des slides.

```
[2]: print('Messages totaux      : ', len(df))
print('Comptes uniques       : ', df['Author'].nunique())
print('Langue                : ', df['Language'].unique(), '(100% FR)')
print('Part de RETWEET       : {:.1f}%'.format((df['Engagement_
↳ Type'] == 'RETWEET').mean()*100))
print('Messages originaux    : ', df['Engagement Type'].isna().sum())
print()
print(df['Engagement Type'].value_counts(dropna=False))
```

```
print()
print('==> LECTURE : 85.8% de retweets, seulement 671 messages originaux.')
print("    La crise est une CAISSE DE RÉSONANCE, pas une production massive de_
    ↳contenu.")
print('    Quasiment tout le volume = de 1 amplification.')
```

```
Messages totaux      : 35396
Comptes uniques      : 10437
Langue               : ['fr'] (100% FR)
Part de RETWEET      : 85.8%
Messages originaux   : 671
```

```
Engagement Type
RETWEET      30368
REPLY        3623
QUOTE        734
NaN          671
Name: count, dtype: int64
```

```
==> LECTURE : 85.8% de retweets, seulement 671 messages originaux.
    La crise est une CAISSE DE RÉSONANCE, pas une production massive de contenu.
    Quasiment tout le volume = de 1 amplification.
```

1.3 2. AXE PROPAGATION — Timeline, pics, vitesse

Comment ça circule ? Patient zéro, pics de volume, vitesse, amplitude.

```
[3]: daily = df.set_index('Date').resample('D').size()
    hourly = df.set_index('Date').resample('h').size()


    print('TOP 5 jours en volume:')
    print(daily.sort_values(ascending=False).head(5))
    print()
    print('Heure de pic max:', hourly.idxmax(), '->', hourly.max(), 'messages/h')

    fig, ax = plt.subplots(figsize=(13,4))
    daily.plot(ax=ax, color='#5B21B6', lw=2)
    ax.set_title('Timeline de la crise - volume de messages par jour')
    ax.set_ylabel('Messages / jour'); ax.set_xlabel('')
    ax.axvspan('2026-03-26', '2026-03-30', alpha=0.12, color='red')
    plt.tight_layout(); plt.show()
```

```
TOP 5 jours en volume:
Date
2026-03-27    7303
2026-03-26    6775
2026-03-29    4932
2026-03-28    3988
```


2026-03-30 2012
dtype: int64

Heure de pic max: 2026-03-26 16:00:00 -> 751 messages/h



```
[4]: # Zoom horaire sur la fenêtre de crise - montre la VITESSE
crise = df[(df['Date']>='2026-03-25')&(df['Date']<'2026-03-31')]
ch = crise.set_index('Date').resample('h').size()
fig, ax = plt.subplots(figsize=(13,4))
ch.plot(ax=ax, color='#EA580C')
ax.set_title('Vitesse - volume horaire pendant le pic (25-30 mars)')
ax.set_ylabel('Messages / heure'); plt.tight_layout(); plt.show()

print('Patient zéro candidat (1er message original) :')
orig = df[df['Engagement Type'].isna()].sort_values('Date')
print('  ', orig['Date'].iloc[0], '|', orig['Author'].iloc[0])
```



Patient zéro candidat (1er message original) :
2026-03-20 02:00:41 | samos_84

Lecture propagation : la crise explose le **26-27 mars** (pic à 7 300 msg/jour, 751 msg/h le 26 à 16h), reste forte 4 jours, puis retombe brutalement le 31. Profil classique de *flambée virale* : montée fulgurante, plateau court, extinction rapide.

1.4 3. AXE ACTEURS — Qui parle ? Qui amplifie ?

Médias, militants, influenceurs, anonymes, comptes suspects.

Distinction clé : **qui POSTE beaucoup** (volume) **qui est AMPLIFIÉ** (influence réelle).

```
[5]: print('--- Comptes qui POSTENT le plus (volume brut) ---')
print(df['Author'].value_counts().head(10))
print()
print('--- Comptes les plus AMPLIFIÉS (= sources des retweets) ---')
rt = df[df['Engagement Type']=='RETWEET']
top_amp = rt['X Repost of'].value_counts().head(10)
print(top_amp)
print()
print('==> Les vrais moteurs de la crise sont les comptes AMPLIFIÉS,')
print('    pas les comptes qui spamment. On y voit des élus (Bellamy,')
print('    Maréchal), des comptes militants, et le CNC lui-même.')
```

--- Comptes qui POSTENT le plus (volume brut) ---

Author

LaPravda99	111
alain_co	108
Alain_83740	105
RabbinAvZemmour	101
nraednioa	97
3_V75	89
Zeauran	88
SYKANHO	87
ppcs27	85
smav31	74

Name: count, dtype: int64

--- Comptes les plus AMPLIFIÉS (= sources des retweets) ---

X Repost of

http://twitter.com/LeDindonFiscal/statuses/2038199978619703349	654
http://twitter.com/Crohnfighter/statuses/2045798671430582710	623
http://twitter.com/charlesvillaa/statuses/2037979931444158475	596
http://twitter.com/jon_delorraine/statuses/2037550734615409015	572
http://twitter.com/fxbellamy/statuses/2037939134992441518	570
http://twitter.com/LeCNC/statuses/2037169894253302130	509
http://twitter.com/MarionMarechal/statuses/2037597335652348246	493
http://twitter.com/anatolium/statuses/2037589531411509333	488
http://twitter.com/GuilhemCarayon/statuses/2037145102074700023	420
http://twitter.com/ojim_france/statuses/2037211245720359162	412

Name: count, dtype: int64

==> Les vrais moteurs de la crise sont les comptes AMPLIFIÉS,
 pas les comptes qui spamment. On y voit des élus (Bellamy,
 Maréchal), des comptes militants, et le CNC lui-même.

1.5 4. AXE NARRATIFS — Quels discours ?

« Copinage » vs « censure » vs « défense d'Ultia ». Mots-clés, thématiques.

```
[6]: # Hashtags
c = Counter()
for row in df['Hashtags'].dropna():
    for tag in str(row).replace(';', ',').split(','):
        tag = tag.strip().lower()
        if tag: c[tag] += 1
print('TOP 15 hashtags:')
for t, n in c.most_common(15): print(f' {n:>4} {t}')
```

/\ PIÈGE détecté : #racketfiscal / #carburant / #vachealait arrivent en tête
-> ce sont des retweets PARASITES (pub/arnaque) qui polluent le corpus.
Le hashtag réellement lié au sujet est #cnc (446) et #ultia (177).

TOP 15 hashtags:

```
655 #racketfiscal
655 #carburant
655 #vachealait
446 #cnc
177 #ultia
51 #twitch
46 #cinéma
46 #europel
46 #europelmatin
46 #scandale
41 #francetv
39 #breakingnews
39 #ue
33 #subventions
32 #qag
```

```
[7]: # Mots les plus fréquents dans les messages normalisés (hors stopwords basiques)
stop = set('rt le la les de des du un une et a à en au aux pour que qui ce se_
↳sur'
        ' pas plus son sa ses est il elle on vous nous je tu ne dans par_
↳avec'
        ' mais ou où donc or ni car the of to vous etre être fait font'.
↳split())
words = Counter()
for t in df['message_normalizer'].dropna():
    for w in str(t).split():
        w = w.strip('.,!()?[]"\'':;@#')
        if len(w) > 3 and w not in stop: words[w] += 1
print('TOP 25 mots du corpus:')
for w, n in words.most_common(25): print(f' {n:>5} {w}')
```

TOP 25 mots du corpus:

21900	https
12815	argent
11396	euros
9494	gauche
9213	français
9168	cette
8238	ultia
8141	talent
7416	tout
7210	public
7001	sans
6877	france
6805	extreme
6322	commission
6215	fonds
6143	meme
5988	votre
5969	millions
5708	bien
5646	droite
5558	tous
5428	comme
5385	subventions
5368	finance
5046	entre

1.6 5. AXE COORDINATION — Est-ce orchestré ?

Synchronies, copier-coller, comptes récents, clusters.

Signal le plus parlant : **les messages identiques copiés en masse.**

```
[8]: mn = df['message_normalizer'].dropna()
vc = mn.value_counts()
dup = vc[vc>1]
print(f'Textes dupliqués (postés >1 fois) : {dup.sum()} messages sur {len(mn)} '
      f'({dup.sum()/len(mn)*100:.0f}% du corpus)')
print()
print('TOP 5 textes les plus copiés:')
for t,n in vc.head(5).items():
    print(f'  x{n}  {str(t)[:80]}')
print()
print('==> ATTENTION nuance : un fort taux de copier-coller en analyse Twitter')
print('    = surtout des RETWEETS (reprise mécanique), PAS forcément une')
print('    coordination malveillante. Il faut séparer retweet vs quote/reply')
print('    identiques pour vraiment parler de coordination.')
```

Textes dupliqués (postés >1 fois) : 29959 messages sur 35396 (85% du corpus)

TOP 5 textes les plus copiés:

```
x654 rt @ ledindonfiscal 111 , 50 pour 52 litres de diesel . À 2 , 12 le
litre , je
x623 rt @ crohnfighter vous vous souvenez des 2 idiots rances camille et
justine , q
x596 rt @ charlesvillaa vous etes un élu de la republique et vous diffusez
une fausse
x572 rt @ jon _ delorraine ce que les francais demandent : que charles
alloncle se pe
x570 rt @ fxbellamy nommee par le cnc dans la commission qui distribue les
fonds du p
```

==> ATTENTION nuance : un fort taux de copier-coller en analyse Twitter
= surtout des RETWEETS (reprise mécanique), PAS forcément une
coordination malveillante. Il faut séparer retweet vs quote/reply
identiques pour vraiment parler de coordination.

```
[9]: # Coordination plus fine : textes ORIGINAUX/quotes identiques (hors retweet)
non_rt = df[df['Engagement Type']!='RETWEET']
vc2 = non_rt['message_normalizer'].dropna().value_counts()
print('Textes non-retweet copiés >1 fois (signal de coordination réel):')
for t,n in vc2[vc2>1].head(10).items():
    print(f' x{n} {str(t)[:80]}')
```

Textes non-retweet copiés >1 fois (signal de coordination réel):

```
x9 quand on analyse les beneficiaires du fond , on comprend qu il ne s agit
pas d u
x3 voici ce que j ai transmis au cnc : fyi . transmis cnc , ministere , gpe
canal ,
x3 voila ce que j ai transmis au cnc avec un espoir de retour , disons ,
faible . f
x3 Ça fait des annees que tout le monde dit qu il se servent mechamment du
cnc , ma
x3 voila ce que j ai transmis au cnc avec un espoir de retour , disons ,
faible . o
x2 # seriesmania2026 : le forum ouvre les portes de sa music room afin de
mettre en
x2 @ lecnc @ gaetanbruel @ ministerecc @ challoncle est ce normal que l
impot des
x2 @ sebmusset ils vont reussir a faire passer la pilule en faisant sauter
le fusi
x2 « nuestra tierra » : le premier # documentaire de lucrecia martelhttps :
/ / t
x2 j attends toujours une reponse . je vais attendre longtemps ! fyi .
transmis cnc
```



1.7 6. AXE SÉMANTIQUE — Sur quel ton ?

Sentiment, montée en agressivité, glissements de vocabulaire.

```
[10]: print('Sentiment global:')
print(df['Sentiment'].value_counts())
print(' -> 66% neutre, 31% négatif, 3% positif')
print()
# Sentiment dans le temps
d = df.set_index('Date')
neg = d[d['Sentiment']=='negative'].resample('D').size()
tot = d.resample('D').size()
ratio = (neg/tot*100).round(1)

fig, ax = plt.subplots(figsize=(13,4))
ratio.loc['2026-03-20':'2026-04-05'].plot(ax=ax, marker='o', color='#DC2626')
ax.set_title('Part de messages négatifs par jour (%)')
ax.set_ylabel('% négatif'); ax.axhline(31, ls='--', color='grey', alpha=.5)
plt.tight_layout(); plt.show()
print('Pic de négativité: 25 mars (42%) et 28 mars (41%) - la tension monte,
      ↪AVANT')
print('le pic de volume, puis culmine pendant.')
```

```
Sentiment global:
Sentiment
neutral      23476
negative     10861
positive      1059
Name: count, dtype: int64
-> 66% neutre, 31% négatif, 3% positif
```



Pic de négativité: 25 mars (42%) et 28 mars (41%) - la tension monte AVANT le pic de volume, puis culmine pendant.

1.8 7. Synthèse — la grille 5 axes remplie (brouillon pour les slides)

Axe	Chiffre clé	Lecture
Propagation	Pic 26-27 mars, 7300 msg/j, 751 msg/h	Flambée virale : montée fulgurante, plateau 4j, extinction le 31
Acteurs	10 437 comptes, 9% certifiés	Moteurs = comptes amplifiés (élus, militants), pas les spammeurs
Narratifs	#cnc (446), #ultia (177)	+ hashtags parasites (#racketfiscal) à filtrer
Coordination	85% de textes dupliqués	MAIS = retweets surtout ; coordination réelle à isoler hors-RT
Sémantique	31% négatif, pics à 42%	Tension monte avant le volume, culmine pendant

1.8.1 3 chiffres clés à mettre en avant

1. **85,8% de retweets** → une crise d'amplification, pas de création.
2. **Pic à 751 messages/heure** le 26 mars 16h → vitesse de déferlement.
3. **Seulement 671 messages originaux** sur 35 396 → tout repose sur une poignée de sources.

1.8.2 Pistes d'agents (pour Jour 2 — à valider en équipe)

- **Agent Détecteur de pic** : surveille le volume horaire, alerte quand ça s'emballe.
- **Agent Classifieur de narratifs** : range chaque message dans censure / copinage / défense.
- **Agent Nettoyeur de bruit** : isole les retweets parasites (pub/arnaque) du vrai sujet.
- **Agent Cartographe d'acteurs** : distingue amplificateurs réels vs comptes à volume.